

Sadržaj

Uvod.....	1
1. Pregled stanja tehnike	2
1.1. CST-YOLO.....	3
1.2. Podaci.....	4
2. Prijedlog poboljšanja	5
2.1. Ideja.....	5
2.2. Kako	5
2.2.1. MCS2	7
2.2.2. MCS3	7
2.2.3. WELAN3	8
2.2.4. WELAN4	8
3. Rezultati i diskusija.....	9
3.1. Kvantitativni rezultati	9
3.1.1. Parametri modela i njihova objašnjenja	9
3.1.2. Usporedba rezultata tablice	10
3.1.3. Usporedba matrica zabune	12
CST-YOLO.....	12
MCS2 i MCS3.....	13
WELAN3 i WELAN4.....	15
3.2. Kvalitativni rezultati	17
CST-YOLO.....	17
MCS2	19
MCS3	20
WELAN3	21

WELAN4	22
Usporedba 1	24
Usporedba 2	26
Usporedba 3	27
Usporedba 4	28
Usporedba 5	30
4. Zaključak.....	31
Literatura.....	32
Sažetak	34

Uvod

Računalni vid i duboko učenje dokazali su se kao važni alati u biomedicini, osobito u analizi medicinskih slika. Njihova primjena ubrzava proces dijagnostike i povećava preciznost detekcije detalja u medicinskim slikama [1]. Jedan od ključnih izazova u ovoj domeni je analiza mikroskopskih slika krvi, koja zahtijeva visoku točnost u detekciji malih i gusto raspoređenih objekata [2].

Detekcija i klasifikacija krvnih stanica ima široku primjenu u hematologiji, od rutinskih krvnih pretraga do dijagnostike malignih bolesti. Manualna analiza mikroskopskih uzoraka je dugotrajna i subjektivna, pa automatizirana rješenja mogu osigurati brže, objektivnije i standardizirane rezultate. Primjerice, broj i morfologija bijelih krvnih stanica ključni su za prepoznavanje infekcija, dok abnormalnosti u crvenim krvnim stanicama mogu ukazivati na anemiju. Stoga su precizni algoritmi detekcije od velikog značaja za poboljšanje kvalitete zdravstvene skrbi [3].

Detekcija malih objekata predstavlja poseban izazov zbog njihove niske rezolucije, sličnosti s pozadinom i čestog preklapanja s drugim strukturama. U kontekstu analize krvnih stanica, to se očituje u poteškoćama pri prepoznavanju trombocita, također prisutan problem je i preklapanje crvenih krvnih stanica. [4]

U ovom radu koristi se CST-YOLO [5] za detekciju i lokalizaciju krvnih stanica u mikroskopskim snimkama klasificirajući: crvene krvne stanice (RBC), bijele krvne stanice (WBC) i trombocite (eng. *platelets*). CST-YOLO je napredna varijanta YOLO (eng. *You Only Look Once*) arhitekture, poznate po svojoj brzini i učinkovitosti. Također u CST-YOLO-u se koristi i arhitektura CNN-SWIN Transformator [5], vizualni transformator koji koristi pomaknute prozore (eng. *Shifted WINDOWS*, kratica SWIN) u kombinaciji s konvolucijskim neuronskim mrežama. Kombinacija od CNN-SWIN Transformatora (CST) i YOLO-a poboljšava detekciju manjih objekata kombinirajući lokalne ekstrakcije značajki CNN-a i globalno-kontekstualnog razumijevanja SWIN Transformatora.

U ovome radu će se pregledati prijedlog rješenja CST-YOLO, te prijedloge poboljšanje te arhitekture. CST-YOLO kod je dostupan na Github poveznici [6], a kod ovog rada na Githubu [7].

1. Pregled stanja tehnike

YOLO [8] serija modela predstavlja jednu od trenutačno popularnijih i učinkovitijih modela detekcije objekata na području računalnog vida. YOLO modeli, počevši od YOLOv1 [8] do najnovijih verzija kao YOLOv9 [9], kontinuirano su poboljšavani u točnosti i brzini.


YOLOv7 [10] svojim izdanjem uvodi nove inovacije poput E-ELAN (eng. *Extended Efficient Layer Aggregation Networks*) i SPPCSPC (eng. *Spatial Pyramid Pooling & Cross Stage Partial Network plus CBS*) modula koji poboljšavaju sposobnost mreže za agregaciju značajki na različitim razinama, te uzimanje globalnog konteksta u analiziranju lokalnih značajki.

U posljednje vrijeme, vizualni transformatori postaju sve popularniji u prostoru računalnog vida zbog svojih sposobnosti hvatanja globalnih ovisnosti. SWIN Transformator se posebno ističe kao varijanta koja koristi pomaknute prozore (eng. *shifted windows*) za samopažnju (eng. *self-attention*) što mu omogućava bolju interakciju između različitih dijelova slike.

Kombinacija konvolucijskih mreža (CNN, eng. *Convolutional neural networks*) i SWIN-Transformatora, poznata kao CST (CNN-SWIN Transformator) pokazala je odličnom u detekciji manjih objekata [11]. Ova hibridna arhitektura nadmašuje tradicionalne YOLO modele na zadacima poput detekcije krvnih stanica, gdje objekti zahtijevaju preciznu lokalizaciju.

Jedna od bitnijih komponenti korištenih u YOLOv7 je CBS (ConvBNSiLU) koji je modul jedne grane koja se sastoji od konvolucijskog sloja, normalizacije minigrupe i sigmoidno-otežane linearne jedinice.

1.1. CST-YOLO



Slika 1 Arhitektura modela CST-YOLO (preuzeto iz [5])

CST-YOLO je inovativan pristup detekciji malih objekata. Ovakav tip modela kombinira prednosti YOLOv7 arhitekture s modulom SWIN transformatora čime stvara hibridnu CNN-Transformator mrežu s poboljšanim hvatanjem globalnih ovisnosti i povećanom preciznošću i odzivom (eng. *recall*) [12]. Rad CST-YOLO uvodi četiri nova modula u arhitekturu: CST (eng. *CNN-SWIN Transformer*) W-ELAN (eng. *Weighted Efficient Layer Aggregation Network*), MCS (eng. *Multiscale Channel Split*) i CatConv (eng. *Concatenate Convolutional Layers*). Model CST-YOLO prikazan je na slici 1.

CST paralelno koristi konvolucijske slojeve i SWIN Transformator kako bi poboljšao ekstrakciju globalnih značajki. SWIN Transformator koristi mehanizam samopažnje što mu omogućuje bolju interakciju značajki između različitih dijelova slike. Njime se povećava preciznost u detekciji sitnih objekata poput trombocita zbog boljeg razumijevanja globalnog konteksta

W-ELAN je poboljšana verzija E-ELAN modula predstavljenog u YOLOv7. On kombinira značajke te dodjeljuje veće težine korisnim značajkama, a manje onima koje su manje korisne.

MCS koristi četiri filtra različitih prostornih veličina čime omogućuje modelu da analizira značajke u različitim skalama. Koristi se i pažnja po kanalima za pojačanje korisnih i prigušenje nevažnih kanala.

CatConv je modul osmišljen da zamijeni MaxPool korišten u YOLOv7 i uvodi bogatiju fuziju značajki s pomoću dodatnih konvolucijskih slojeva. Umjesto da kao MaxPool uzima samo najveće vrijednosti, on koristi više paralelnih konvolucijskih slojeva koji izvlače različite značajke koje se spajaju (*concat*).

Eksperimentalni rezultati [5] pokazuju da CST-YOLO nadmašuje model YOLOv7 na tri različita skupa podataka za detekciju krvnih stanica, postižući bolju preciznost, ali s gubitkom brzine. No glavna prednost kod YOLOv7 naspram CST-YOLO je brzina, gdje je performanca CST-YOLO-a 235.6 GFLOPS (eng. *Giga Floating Point Operations Per Second*) što je znatno više nego YOLOv7 čija je performanca 103.4 GFLOPs-a.

1.2. Podaci

Za treniranje, validaciju i testiranje modela koristile su se tri baze podataka Blood Cell Count and Detection (BCCD) [13], Complete Blood Count (CBC) [14] i Blood Cell Detection (BCD) [15]. To su baze sa slikama krvnih stanica slikane mikroskopom. Razlikuju tri krvne stanice (crvene krvne stanice, bijele krvne stanice i trombocite). Baze se razlikuju po broju podataka, rezolucijama i podjelom na skupove učenje, validaciju i testiranje.

BCCD dataset sadrži 364 slika u rezoluciji 640x480, a CBC 420 u rezoluciji 416x416. BCD se sastoji od 874 slika. Particije slika prikazane su u tablici 1.

Tablica 1 Particija baze podataka

Dataset	train	validation	test	ukupno
BCCD	205	87	72	364
CBC	300	60	60	420
BCD	765	73	36	874
all	1270	220	168	1658


2. Prijedlog poboljšanja

U ovom poglavlju su opisani prijedlozi za optimizaciju CST-YOLO arhitekture s ciljem povećanja brzine izvođenja uz zadržavanje visoke preciznosti. Predložena su četiri modela koji se fokusiraju na pojednostavljenja komponenti MCS i W-ELAN.

2.1. Ideja

Glavni problem CST-YOLO arhitekture je njegova slaba brzina [5]. Iako dobiva visoku preciznost u odnosu na YOLOv7, znatno ima manju brzinu gdje je CST-YOLO 235.6 GFLOPs-a, a YOLOv7 s 103.4 GFLOPs-a. Zbog toga cilj ovog rada je pokušati ubrzati CST-YOLO bez velikog gubitka u preciznosti. Važno je napomenuti da u slučaju medicinske analize važnija je točnija preciznost nego veća brzina.


2.2. Kako




Slika 2.1 modul MCS (preuzeto iz [5])

Prva promjena je promjena modula MCS. MCS je modul predstavljen u radu CST YOLO, njegova struktura prikazana je na slici 2.1. Kroz MCS značajke prolaze kroz četiri grane koje se sastoje od slojeva sažimanja usrednjavanjem (eng. *AvgPool*), nakon čega prolaze kroz CBS čime se dobiju u svakoj grani četiri mape značajki. Prije spajanja grana koristi se nadočitavanje (eng. *Upsample*). Spaja se s pomoću ulančavanja (eng. *Concat*) nakon čega se koristi sažimanje usrednjavanjem i sigmoidna aktivacijska funkcija. Kako bi se smanjila računska složenost, značajke se dijele na četiri dijela po kanalima, pa se zatim sumiraju. Konačno primjenjuje se 1x1 konvolucija za konačnu prilagodbu kanala te se dodaje rezidualni spoj kako bi se očuvala informacija. Ova komponenta omogućuje modelu bolji detekciju malih

objekata poput krvnih stanica. Iako se MCS dokazao korisnim u detekciji manjih krvnih stanica njegova izvedba je relativno spora zbog složenosti operacija te višestrukog grananja.




Slika 2.2 modul W-ELAN1 (preuzeto iz [5])



Slika 2.3 modul W-ELAN2 (preuzeto iz [5])

Druga promjena je promjena W-ELAN modula. U samom CST-YOLO radu predstavljene su dvije inačice W-ELAN modula; W-ELAN1 (slika 2.2) i W-ELAN2 (slika 2.3). Navedeno je kako je W-ELAN inspiriran E-ELAN-om i EfficientDet-om. W-ELAN početnu mapu značajki razdvaja u dvije grane, prva grana prolazi kroz pet CBS-a, a druga grana kroz jedan. U slučaju W-ELAN1 grane se spajaju s pomoću Concat sa izlaznim mapama značajki od prvog, trećeg i petog CBS-a prve grane, dok u slučaju W-ELAN2 uz dvije grane spajaju se i izlazi prvog, drugog, trećeg, četvrog i petog CBS-a prve grane. Pri spajanju grana svakoj mapi značajki pridjeljuje se težina. Težine pridijeljene mapama su parametri koji se mogu učiti tijekom treniranja. Ako neka mapa doprinese modelu u točnom zaključivanju, njena težina se povećava.

2.2.1. MCS2



Slika 2.4 modul MCS2

Prvi prijedlog ubrzanja modela uključivao je izmjenu strukture MCS modula, koji se u originalnoj verziji grana u četiri paralelne grane s različitim skalama 1.25, 2, 2.5 i 4. U modulu MCS2, uklonjene su najmanja i najveća grana (1.25 i 4) dok su zadržane grane srednjih skala (2 i 2.5), vidljivo na slici 2.4. Time se smanjuje broj kanala koji se generiraju i spajaju u MCS-u, čime se značajno smanjuje memorijska i računalna složenost, što rezultira bržom obradom.


Model koji koristi ovu verziju modula nazvan je MCS2, te u odnosu na izvorni CST-YOLO model sadrži oko 4.1% manje parametara i smanjenje računalne složenosti (GFLOPS) s 235.4 na 156.1 što nam pokazuje jasnu optimizaciju u računanju.

2.2.2. MCS3

Drugi pristup optimizaciji modela također je bio temeljen na promjeni strukture MCS modula, ali ovoga puta s drugačijim odabirom grana. Za razliku od MCS2, novi modul MCS3 zadržava grane s najvišom i najmanjom skalom (1.25 i 4), dok uklanja srednje grane (2 i 2.5). Ovim pristupom se također postiže smanjenje broja izlaznih kanala iz MCS modula i posljedično manja memorijska i računalna zahtjevnost modela.

Model koji koristi ovu verziju modula nazvan je MCS3, te zadržava isti broj parametara kao MCS2 (4.1 % manje parametara u odnosu na CST-YOLO), no ostvaruje veću računalnu složenost s GFLOPS 168.4. To nam pokazuje na veću računalnu potrošnju u odnosu na MCS2, ali uz moguće bolje zadržavanje informacija zahvaljujući širem rasponu veličina kernela.

2.2.3. WELAN3



Slika 2.5 modul W-ELAN3 i W-ELAN4

Sljedeći prijedlog ubrzanja modela je bio promjenom modula W-ELAN1. Iz W-ELAN1-ove prve grane, koja sadrži 5 modula CBS, uklonjeni su drugi i četvrti CBS blokovi, vidljivo na slici 2.5. Time smanjujemo broj konvolucija te time i broj parametara, i broj GFLOPS.

Modul WELAN3 zamjenjuje modul W-ELAN1 s modulom W-ELAN3. Time se uveliko smanjuje broj parametara za 5.2 % u odnosu na CST-YOLO. Računalna složenost je također smanjena s 235.4 na 223.3, što znači da je računalna složenost smanjena.

2.2.4. WELAN4

Modul WELAN-4 zadržava istu strukturu kao modul WELAN-3, ali se primjenjuje na W-ELAN2 umjesto na W-ELAN1. Time se smanjuje broj CBS blokova u W-ELAN2, ali se smanjuje i broj grana koje kasnije ulančavaju, te se time smanjuje i broj pridijeljenih težina.

Ova zamjena dodatno smanjuje broj parametara za ukupno 10.9 %. Iako broj operacija neznatno raste u odnosu na WELAN3 na 226.9 GFLOPS on i dalje ostaje ispod vrijednosti originalnog CST-YOLO-a.

3. Rezultati i diskusija

Preuzimamo CST-YOLO model s njihovog javnog githuba [6] i baze BCCD [13], BCD [15] i CBC [14]. Nakon čega pripremimo baze za treniranje. Skupove podataka spajamo u jedinstveni skup radi jednostavnijeg upravljanja. Tijekom treniranja i testiranja ovih modela korištena je NVIDIA TITAN Xp. Korišteni hiperparametri su stopa učenja 0.001 s *cosine annealing learning rate schedule*-om s *weight decay rate*-om 0.0005. *Batch size* je 32, a trenirano je na 100 epoha. Za treniranje korišten je *batch size* 32, a trenirano je na 100 epoha. Za testiranje korišten je *batch size* 4.

Testiranje je provedeno na NVIDIA TITAN Xp s *batch size*om 4 i IoU (*Intersection over Union*) od 0.65. *Conf-threshold* varira za svaki model, izračinat prema F1 krivulji, a oni su 0.285 za CST-YOLO, 0.363 za MCS2, 0.339 za MCS3, 0.187 za WELAN3 i 0.222 za WELAN4. Izračunato vrijeme inferencije za svaki model je prosjek od deset provedenih testova.

Razmatraju se kvantitativni i kvalitativni rezultati. Od kvantitativnih uspoređujemo brojne rezultate dobivene testovima, a od kvalitativnih promatramo slikovne rezultate dobivene detekcijama pojedinih modela.

3.1. Kvantitativni rezultati

U kvantitativnim rezultatima se analiziraju modeli prema parametrima dobivenim programom test.py [6].

3.1.1. Parametri modela i njihova objašnjenja

Broj parametara predstavlja ukupan broj treniranih parametara u modelu, ti parametri su težine koje model uči tijekom treninga. Veći broj znači sporiji trening, ali i veću ekspresivnost modela za učenje. No prevelikim porastom lako je doći do problema s prenaučenošću (*overfitting*), gdje model previše pamti podatke treninga i smanjuje se generalizacija modela. U tablici broj parametara je skaliran prema broju parametara referentnog modela CST-YOLO koji sadrži 47,495,499 parametara.

GFLOPS (*Giga Floating Point Operations Per Second*) je mjera količine računskih operacija koje model mora izvršiti za jednu inferenciju (predikciju iz slike). Viši GFLOPS

znači veći zahtjev za računalnim resursima i sporiju inferenciju. U tablici GFLOPS je skaliran prema GFLOPS početnog modela CST-YOLO koji iznosi 235.4.

Preciznost (P, *precision*) i odziv (R, *recall*) ključne su metrike za procjenu performansi modela detekcije objekata. Preciznost izražava koliko je model pouzdan pri davanju pozitivnih predikcija, a odziv mjeri koliko dobro model prepoznaje sve stvarne objekte u skupu podataka. Ako bi preciznost bila jednaka jedan, značilo bi da svaki predviđeni objekt je istinit, a ako bi bila jednaka 0, to bi značilo da ni jedan predviđen objekt nije točno predviđen.

mAP@.5 (*mean Average Precision*) je prosječna preciznost kroz svaku klasu, gdje je detekcija točna ako je IoU (*Intersection over Union*, presjek preko unije) barem 0.5 između predviđenog i točnog. IoU se računa kao $(\text{presjek}(A,B)/\text{unija}(A, B))$. Što je mAP@.5 viši to je model bolji u lokalizaciji objekata.

mAP@.5:.95 je sličan kao i mAP@.5, ali on još dodatno traži prosjek mAP-ova kojima su pragovi od 0.5 do 0.95 s korakom od 0.05 (npr. 0.5, 0.55, 0.6, ..., 0.95). Ovo je puno stroža verzija mAP-a. Kao i mAP@0.5, što je mAP@.5:.95 viši to je model bolji u lokalizaciji objekata.

Vrijeme inferencije je vrijeme koje modelu treba da iz ulazne slike proizvede detekcije. Vrijednost vremena inferencije u tablici je prosjek vremena inferencije od deset provedenih testova.

3.1.2. Usporedba rezultata tablice

Tablica 2 Rezultati treniranja i testiranja

Model	Broj parametara (skalirano /47.5 M)	GFLOPS (skalirano /235.4)	P all	R all	mAP@.5 all	mAP@.5:.95 all	Vrijeme inferencije (ms)
CST-YOLO	1	1	0.730	0.726	0.733	0.538	14.47
MCS2	0.959	0.663	0.725	0.775	0.699	0.522	14.2
MCS3	0.959	0.715	0.708	0.818	0.735	0.533	14.25
WELAN3	0.948	0.949	0.694	0.770	0.717	0.514	13.69
WELAN4	0.891	0.964	0.673	0.814	0.748	0.551	13.8

U ovoj usporedbi rezultata razmatra se učinkovitost optimiziranih varijanti modela CST-YOLO; MCS2, MCS3, WELAN3 i WELAN4 s ciljem smanjenja računalne složenosti s održavanjem preciznosti detekcije objekata pomoću tablice 2. Svi modeli trenirani su samo jednom, bez provođenja unakrsne validacije, što znači da rezultati predstavljaju indikativne vrijednosti, ali ne i potpuno pouzdanu generalizaciju. Za potpuniju i pouzdaniju procjenu, potrebno je provesti unakrsnu validaciju uz različite početne uvjete treniranja.

Referentni model, CST-YOLO, u ovoj tablici predstavlja osnovnu točku za usporedbu s ostalim modelima. S najvećim brojem parametara (1.0 odnosno 47.5 M) i najvećom računalnom složenošću (1.0 odnosno 235.4 GFLOPS) nudi solidnu ravnotežu točnosti i brzine s mAP@.5 koji iznosi 0.733, mAP@.5:.95 je 0.538, dok je vrijeme inferencije 14.47 ms. No optimiziranim varijantama će se pokazati kako se ta ravnoteža može potencijalno dodatno poboljšati.

MCS2 se pokazao kao vrlo efikasan model. Ima gotovo isti broj parametara (0.959) kao CST-YOLO, ali znatno nižu računalnu složenost (0.663). Unatoč tome, ostvaruje viši recall (0.775) te nešto niži mAP@.5 (0.699) i mAP@.5:.95 (0.522), uz kraće vrijeme inferencije (14.2 ms). To ga čini odličnim kompromisom između brzine i točnosti, posebno pogodnim za primjene gdje je optimizacija performansi važna.

MCS3, iako ima iste parametre kao MCS2 (0.959), koristi drugačiju unutarnju arhitekturu (GFLOPS: 0.715) i postiže još bolji recall (0.818). Također postiže najbolji mAP@.5 među svim modelima (0.735), dok je mAP@.5:.95 također visok (0.533). Vrijeme inferencije ostaje konkurentno (14.25 ms). Ovi rezultati pokazuju da pravilnim balansiranjem strukture model može nadmašiti čak i referentni CST-YOLO u preciznosti.

WELAN3 predstavlja model sa smanjenim brojem parametara (0.948) i nešto nižim GFLOPS-om (0.949). Iako ostvaruje nešto niži mAP@.5 (0.717) i mAP@.5:.95 (0.514) u odnosu na CST-YOLO, postiže vrlo konkurentan recall (0.770) te najbrže vrijeme inferencije od svih modela (13.69 ms). WELAN3 je stoga primjeren za aplikacije gdje je brzina ključna.

WELAN4 dodatno reducira broj parametara (0.891) uz GFLOPS od 0.964. Iako nije najjednostavniji model po složenosti, postiže najbolje ukupne rezultate: recall od 0.814, mAP@.5 od 0.748, te mAP@.5:.95 od 0.551. S obzirom na vrijeme inferencije od 13.8 ms, WELAN4 nudi najbolju preciznost uz zadržanu učinkovitost, i time je najtočniji model u usporedbi.

Zaključno, na temelju vrijednosti rezultata, MCS2 se izdvaja kao najbolja opcija od četiri ispitivanje kada je cilj maksimizirati brzinu uz minimalan gubitak točnosti, dok je WELAN4 najprikladniji kada je prioritet visoka točnost detekcije. S obzirom na ograničenja metodologije, posebno činjenicu da je svaki model treniran samo jednom, ove rezultate treba tumačiti s oprezom. Dodatna evaluacija kroz višestruko treniranje i validaciju bila bi nužna za donošenje zaključaka.

3.1.3. Usporedba matrica zabune

Sljedeće promatraju se matrice zabune (eng. *confusion matrix*). To su tablice koje se koriste za procjenu kvalitete modela klasifikacije. Prikazuju koliko je puta (u našem slučaju koji je postotak) model ispravno ili pogrešno predvidio pripadnost objekta pojedinim klasama. Vrijednosti u matrici se razlikuju od preciznosti i odaziva, pa će se kroz ovo poglavlje zvati točnost detekcije po klasi, ili samo točnost.

CST-YOLO

Tablica 3 Matrica zabune za CST-YOLO

Istina→ Detektirano ↓	WBC	RBC	Trombociti	Lažno pozitivni
WBC	0.99	0.00	0.03	0.01
RBC	0.01	0.95	0.00	0.85
Trombociti	0.01	0.00	0.69	0.13
Lažno pozitivni	0.00	0.05	0.28	0.00

Na tablici 3 prikazana je normalizirana matrica zabune koja prikazuje performanse modela CST-YOLO na zadatku detekcije i klasifikacije krvnih stanica. Ova matrica omogućuje vizualizaciju kako model klasificira pojedine klase (WBC, RBC, *Platelets*) i u kojoj mjeri dolazi do pogrešnih klasifikacija, uključujući i klasifikaciju pozadine kao stanica (*false positives*, FP) te stanica kao pozadine (*false negatives*, FN).

Model pokazuje iznimno visoku točnost pri prepoznavanju bijelih krvnih stanica (WBC), s udjelom točno klasificiranih primjera od čak 99 %. To znači da gotovo svi primjeri bijelih krvnih stanica u testnom skupu bivaju pravilno klasificirani, uz zanemariv broj zamjena s drugim klasama. WBC su stabilna i prepoznatljiva klasa unutar ovog skupa podataka, što može biti posljedica njihove jasne vizualne diferencijacije u odnosu na pozadinu i druge stanice.

Crvene krvne stanice (RBC) također su visoko točno klasificirane, s 95 % točnih predikcija. Unatoč manjoj točnosti u odnosu na WBC, ovaj rezultat je i dalje vrlo zadovoljavajući.

S druge strane, trombociti (Platelets) su prepoznati znatno slabije, ispravno su klasificirani u 69 % slučajeva, dok se u preostalih 31 % slučajeva pogrešno klasificiraju kao pozadina (28 %) ili kao WBC (3 %). To ukazuje na izazove u prepoznavanju trombocita, što može biti posljedica njihove vizualne sličnosti s pozadinom ili neravnoteže u broju uzoraka tijekom treniranja.

Drugi stvar vidljiva u matrici zabune je ta što je od svih lažno pozitivnih detekcija 85 % RBC. Ova pojava ukazuje na to da pozadina u velikom broju slučajeva sadrži karakteristike koje model pogrešno interpretira kao crvene krvne stanice, što može biti posljedica neadekvatna razlika između crvenih krvnih stanica i drugih objekata u pozadini ili same pozadine. Ovo također može biti greška u pripremi baze podataka uzrokovana ljudskom greškom krivog označivanja.

MCS2 i MCS3

Tablica 4 matrica zabune za MCS2

Istina→ Detektirano ↓	WBC	RBC	Trombociti	Lažno pozitivni
WBC	0.99	0.00	0.00	0.01
RBC	0.00	0.89	0.00	0.94
Trombociti	0.01	0.00	0.46	0.05
Lažno pozitivni	0.01	0.11	0.54	0.00

Tablica 5 matica zabune za MCS3

Istina→ Detektirano ↓	WBC	RBC	Trombociti	Lažno pozitivni
WBC	0.99	0.00	0.00	0.01
RBC	0.00	0.91	0.00	0.94
Trombociti	0.01	0.00	0.57	0.05
Lažno pozitivni	0.01	0.09	0.43	0.00

Sljedeće dvije tablice, tablica 4 i tablica 5, prikazuju skalirane matrice zabune modela MCS2 i MCS3.

Matrice zabune MCS2 i MCS3 prikazuju sličan uzorak klasifikacijskih performansi, no postoje i razlike koje ukazuju na određena poboljšanja. Oba modela pokazuju visoku točnost u klasifikaciji WBC i RBC, dok se kod trombocita i pozadine i dalje javljaju problemi, slično kao i kod modela CST-YOLO.

Za model MCS2, točnost u klasifikaciji WBC iznosi 99 %, dok je za RBC 89 %. Trombociti su točno klasificirani u 46 % slučajeva, što ukazuje na značajne poteškoće u njihovom prepoznavanju.

Model MCS3 donosi vidljiva poboljšanja. Iako točnost za WBC ostaje visok (99 %), točnost za RBC raste na 91 %, a i prepoznavanje trombocita se poboljšava s vrijednosti 57 %.

Usporedbom s CST-YOLO modelom, koji postiže 99 % točnosti za WBC, 95 % za RBC i 69 % za trombocite, može se zaključiti da MCS2 ima lošije rezultate u prepoznavanju RBC i posebno trombocita. MCS3, iako zaostaje za CST-YOLO u prepoznavanju trombocita, ostvaruje slične rezultate za WBC i prihvatljive rezultate za RBC.

Zaključno, model MCS2 pokazuje ograničenja u klasifikaciji RBC i osobito trombocita, dok model MCS3 predstavlja poboljšanje u odnosu na njega. Unatoč napretku, kod oba modela, kao i kod CST-YOLO, detekcija trombocita ostaje izazovna i predstavlja područje koje zahtijeva dodatna istraživanja i optimizacije modela.

WELAN3 i WELAN4

Tablica 6 matrica zabune za WELAN3

Istina→ Detektirano ↓	WBC	RBC	Trombociti	Lažno pozitivni
WBC	0.99	0.00	0.03	0.01
RBC	0.00	0.95	0.00	0.89
Trombociti	0.01	0.00	0.78	0.11
Lažno pozitivni	0.00	0.04	0.19	0.00

Tablica 7 matrica zabune za WELAN4

Istina→ Detektirano ↓	WBC	RBC	Trombociti	Lažno pozitivni
WBC	0.99	0.00	0.00	0.01
RBC	0.00	0.96	0.00	0.95
Trombociti	0.01	0.00	0.57	0.04
Lažno pozitivni	0.01	0.04	0.43	0.00

Sljedeće dvije tablice, tablica 6 i tablica 7 predstavljaju skalirane matrice zabune modela WELAN3 i WELAN4.

Oba modela pokazuju visoku točnost u klasifikaciji WBC i RBC, no detekcija trombocita i dalje ostaje izazov, kao i kod modela CST-YOLO, MCS2 i MCS3.

Model WELAN3 postiže točnost od 99 % za WBC i 95 % za RBC, što je na istoj razini kao i CST-YOLO. Međutim, u prepoznavanju trombocita WELAN3 postiže najbolji rezultat među svim modelima sa 78 % točnosti. Iako i dalje postoje određeni problemi s lažno

pozitivnim predikcijama, naročito kod WBC, model pokazuje značajan napredak u klasifikaciji trombocita u odnosu na prethodne modele.

S druge strane, model WELAN4 također bilježi visoke rezultate za WBC i RBC, s točnostima od 99 % i 96 %. Međutim, točnost trombocita kod WELAN4 iznosi 57 %, što predstavlja pad u odnosu na WELAN3. Unatoč tome, rezultati su i dalje usporedivi s CST-YOLO modelom, koji za trombocite ostvaruje točnost od 69 %.

Usporedbom s CST-YOLO modelom može se zaključiti da su WELAN modeli vrlo slični u klasifikaciji WBC i RBC, s minimalnim razlikama. WELAN3 se ističe po najboljoj točnosti u detekciji trombocita, dok WELAN4, iako nešto slabiji po tom pitanju, zadržava konzistentno visoke rezultate za ostale vrste stanica.

Zaključno, modeli WELAN3 i WELAN4 pokazuju stabilne i konkurentne performanse u odnosu na CST-YOLO, s naglaskom na bolju klasifikaciju trombocita kod WELAN3. Ipak, kao i kod ostalih modela, trombociti ostaju najteža klasa za točniju klasifikaciju.

Tablica 8 Usporedba tablica zbunjenosti

Model	WBC	RBC	Trombocita
CST-YOLO	0.99	0.95	0.69
MCS2	0.99	0.89	0.46
MCS3	0.99	0.91	0.57
WELAN3	0.99	0.95	0.78
WELAN4	0.99	0.96	0.57

U tablici 2 stupci predstavljaju vrijednosti postotka točno predviđenih naprema točnoj količini objekata.

Konačno, vidljivo je da svi modeli postižu izvrsne rezultate u klasifikaciji WBC, s točnosti od 99 %. Također, točnost klasifikacije RBC je visoka u svim modelima, krećući se između 89 % (MCS2) i 96 % (WELAN4). Međutim, problem detekcije trombocita ostaje zajednički izazov svim modelima s jasno nižim točnostima u odnosu na WBC i RBC.

Usporedbom svih modela, WELAN3 se ističe kao model s najboljom točnosti u detekciji trombocita (78%), značajno nadmašujući sve ostale. CST-YOLO i WELAN4 postižu jednak rezultat u klasifikaciji WBC (99 %) te vrlo slične rezultate za RBC (95 % i 96 %), no

trombociti su kod CST-YOLO točno klasificirani u 69 % slučajeva, dok kod WELAN4 u 57 %.


Model MCS3 pokazuje uravnotežene performanse, s točnosti od 91 % za RBC i 57 % za trombocite, uz zadržavanje vrhunske točnosti za WBC. S druge strane, MCS2 ima najslabiju točnosti za RBC (89 %) i najnižu za trombocite (46 %), što ga čini najslabijim modelom u usporedbi.

Zaključno, iako je klasifikacija WBC i RBC generalno vrlo pouzdana u svim modelima, detekcija trombocita i dalje predstavlja glavni izazov. Najveći napredak u tom segmentu pokazuje WELAN3, dok MCS2 zaostaje. Lažno pozitivne predikcije, osobito između trombocita i pozadine, i dalje su prisutne i zahtijevaju dodatna poboljšanja kroz daljnju optimizaciju modela.


3.2. Kvalitativni rezultati

U kvalitativnim rezultatima razmatrat će se pojedini primjeri detekcija svakog modela, dobiveni programom detect.py [6], i uspoređivat će se s točnim, očekivanim rezultatima. Svaka detekcija je provedena s pragom pouzdanosti 0.6. Kvalitativni rezultati sadrže po dvije usporedbe između svakog modela sa slikom „istine“ (*ground truth*), koja je generirana s pomoću slike i anotacije iz baze podataka. Poglavlje također sadrži pet usporedba između svih modela.

CST-YOLO




Slika 6 CST-YOLO 00031bccd




Slika 7 istina 00031bccd

U ovom primjeru vide se okviri detekcije kreirani s CST-YOLO modelom (slika 6) i očekivani rezultat (slika 7) za sliku 00031 baze BCCD [13]

CST-YOLO je vrlo uspješan u detekciji WBC. Točno je locirao obje bijele stanice u slici. CST-YOLO je detektirao veći broj RBC-ova (označeni crvenom bojom), od kojih je većina točna, ali vidljivo je da je model propustio označiti nekoliko RBC-ova. Također vidi se da je jedan od okvira detekcija krivo poravnan. Najveći nedostatak modela je potpuni neuspjeh u detekciji trombocita (*platelets*, označeni plavom bojom), dok slika „istine“ jasno prikazuje nekoliko označenih trombocita.



Slika 8 CST-YOLO 00396cbc




Slika 9 istina 00396cbc


U sljedećem primjeru vide se okviri detekcije kreirani s CST-YOLO modelom (slika 8) i očekivani rezultat (slika 9) za sliku 00396 baze CBC [14].

CST-YOLO je u ovome primjeru gotovo točno detektirao sve stanice. Jedina WBC u slici je točno detektirana, a od velikog broj RBC-ova, samo nekoliko je krivo detektirano. Ponovno primjetan je problem s detekcijom trombocita, gdje oba od dva istinita nisu ispravno detektirana.

MCS2




Slika 10 MCS2 00038 bcd




Slika 11 istina 00038 bcd

U ovom primjeru vide se okviri detekcije kreirani s MCS2 modelom (slika 16) i očekivani rezultat (slika 17) za sliku 00038 baze BCD [15].

MCS2 u ovome primjeru odlično primjećuje jedini WBC sa slike, uz malo uži okvir detekcije nego u slici istine. Veliki problem je veliki broj promašenih RBC-a. Veliki broj RBC-ova je jednostavno preskočeno, a uzrok tome može biti teško prepoznavanje u slučaju preklapanja stanica. Također vidljivo je kako oba trombocita nisu dobro prepoznati.



Slika 12 MCS2 00208 bccd




Slika 13 istina 00208 bccd


U sljedećem primjeru vide se okviri detekcije kreirani s MCS2 modelom (slika 18) i očekivani rezultat (slika 19) za sliku 00208 baze BCCD [13].

MCS2 u ovome primjeru primjećuje gotovo savršeno WBC. Velik broj RBC-ova je točno detektirano, ali neke su krivo detektirane, a neke nisu uopće. Ovdje su vidljivi i lažno pozitivne i lažno negativne primjere za RBC.

MCS3




Slika 14 MCS3 00038 bcd




Slika 15 istina 00038 bcd

U ovom primjeru se vide okviri detekcije kreirani s CST-YOLO modelom (slika 16) i očekivani rezultat (slika 17) za sliku 00038 baze BCD [15]. Ista slika kao i za prvi primjer za MCS2.

MCS3 u ovome primjeru odlično primjećuje jedini WBC sa slike. Veliki problem koji vidimo, kao i kod istog primjera kod MCS2, je veliki broj promašenih RBC-a. Veliki broj RBC-ova je jednostavno preskočeno, što također navodi problem modela u prepoznavanju preklopljenih stanica. Također vidi se kako oba trombocita nisu dobro prepoznati.



Slika 16 MCS3 00271 bccd




Slika 17 istina 00271 bccd


U sljedećem primjeru se vide okviri detekcije kreirani s MCS3 modelom (slika 22) i očekivani rezultat (slika 23) za sliku 00271 baze BCCD [13].

MCS3 je odlično detektirao WBC. Također točno je detektirao većinu RBC-ova, s nekim krivo detektiranim ili ne detektiranim. Trombocit nije točno detektiran.

WELAN3




Slika 18 WELAN3 00359 bcd




Slika 19 istina 00359 bcd

U ovom primjeru vidimo okviri detekcije kreirane s MCS3 modelom (slika 24) i očekivani rezultat (slika 25) za sliku 00359 baze BCD [15].

Prvo što možemo primijetiti u ovome primjeru je loša detekcija WBC-a. WELAN3 je u ovom slučaju umjesto jedne WBC prepoznao dvije. Osim toga, pronađeno je točno većinu RBC-ova, a trombociti nisu prisutni.



Slika 20 WELAN3 00383 cbc




Slika 21 istina 00383 cbc


U sljedećem se primjeru vide okviri detekcije kreirani s WELAN3 modelom (slika 26) i očekivani rezultat (slika 27) za sliku 00383 baze CBC [14].

Prva stvar koja se može primijetiti u zadatku je točno pronađen trombocit. Iako su dva promašena ovo je odličan rezultat, iz razloga što se trombociti vrlo rijetko detektiraju s sigurnošću većom od 0.6 kojom su provedeni testovi kvalitativnih rezultata. Osim točno pronađenog trombocita, također su odlično pronađeni RBC-ovi i WBC.

WELAN4




Slika 22 WELAN4 00180 bccd




Slika 23 istina 00180 bccd

U ovom primjeru vidljivi su okviri detekcije kreirani s MCS3 modelom (slika 28) i očekivani rezultat (slika 29) za sliku 00180 baze BCCD [13].

WELAN4 u ovom slučaju odlično detektira WBC, te odlično detektira i velik broj RBC-ova. Glavni problem vidljiv u ovom primjeru je velik broj lažno pozitivno detektiranih RBC-ova. Trombociti nisu detektirani niti očekivani u ovome primjeru.



Slika 24 WELAN4 00375 cbc




Slika 25 istina 00375 cbc

U sljedećem primjeru vidimo okviri detekcije kreirane s WELAN4 modelom (slika 30) i očekivani rezultat (slika 31) za sliku 00383 baze CBC [14].

WELAN4 odlično detektira WBC i gotovo savršeno detektira sve RBC-ove uz samo par loše detektiranih. Trombociti nisu detektirani.

Usporedba 1



Slika 26 Usporedba 1

U ovoj usporedbi analiziramo pet različitih modela sa slike 27 (redom CST-YOLO slika A1, MCS2 slika A2, MCS3 slika A3, WELAN3 slika B1 i WELAN4 slika B2) detekcije krvnih stanica na istoj mikroskopskoj slici (00065 datasea bccd [13]), s ciljem evaluacije njihove preciznosti u odnosu na stvarnu vrijednost (slika B3).

CST-YOLO pokazuje solidnu detekciju WBC-a s točno detektirane dvije stanice. Međutim vidimo da je broj detektiranih RBC-a nešto manji u usporedbi s očekivanim rezultatima s dvije točne od pet. Nema detekcije trombocita.

MCS2 također uspješno detektira WBC-ove. Detekcija RBC-a je nešto bolja, primjećujemo dodatnu točnu detekciju, ali još uvijek nisu pokriveno sve stanice. I ovdje nedostaje detekcija trombocita.


MCS3 ima vrlo sličnu detekciju kao i MCS2, ali s blagim poboljšanjem u pozicioniranju WBC okvira i njihovoj pouzdanosti. RBC detekcija je gora nego u MCS2, ali kao CST-YOLO, sadrži dvije od pet točnih RBC-ova. Trombocit nije detektiran.

WELAN3 postiže vrlo sličan rezultat kao prethodni modeli u pogledu WBC detekcije. Detekcija RBC-a je nešto lošija, primjetna je gora detekcija RBC-ova. Model i dalje ne prepoznaje trombocit.

WELAN4 pokazuje jednu od najboljih detekcija RBC-a među modelima uz MCS2. Prva vidljiva stvar je najviše detektiranih RBC-ova. Detektirana su četiri od pet točnih RBC-ova, uz dva lažno pozitivnih. WBC su precizno locirani. Trombocit nije detektiran.

Svi modeli uspješno prepoznaju WBC stanice s visokom preciznošću, dok je detekcija RBC-a djelomična i varira među modelima. Najpotpuniju RBC detekciju daje WELAN4. Nijedan model ne uspijeva prepoznati trombocite, što je ključna točka za buduće poboljšanje. Referentna Slika 37 jasno ilustrira da modeli imaju prostor za napredak, posebno u detekciji sitnijih i rjeđe prisutnih trombocita. U cjelini, WELAN4 se pokazuje kao generalno najbolji model u ovom uzorku, a odmah iza njega je MCS2 koji je najbolji ako je potreban minimalan broj lažno pozitivnih.

Usporedba 2




Slika 27 Usporedba 2

U ovoj usporedbi se ponovno analiziraju pet različitih modela slikom 28 (redom CST-YOLO slika A1, MCS2 slika A2, MCS3 slika A3, WELAN3 slika B1 i WELAN4 slika B2) detekcije krvnih stanica na istoj mikroskopskoj slici (00374 dataseta CBC [14]), s referentnom slikom stvarne vrijednosti (slika B3).

U ovoj usporedbi vidi se da su većina detekcija modela gotovo identične. Jedina koja odstupa je detekcija modela MCS2 Slika 39 koji sadrži jednu lažno pozitivan RBC.

Usporedba 3



Slika 28 Usporedba 3

U ovoj usporedbi na slici 29 ponovno se analiziraju pet različitih modela (redom CST-YOLO slika A1, MCS2 slika A2, MCS3 slika A3, WELAN3 slika B1 i WELAN4 Slika B2) detekcije krvnih stanica na istoj mikroskopskoj slici (00038 dataseta BCD [15]), s referentnom slikom stvarne vrijednosti (slika B3).

CST-YOLO savršeno detektira WBC s točno detektiranom jedinom stanicom. Većina detektiranih RBC stanica su točne, ali veliki broj RBC-ova nije detektirano. CST-YOLO također uspješno pronalazi jedan od dva trombocita, što je veliki uspjeh.

MCS2 također savršeno detektira WBC. Detekcija RBC je drugačija s različito detektiranim stanicama, ali s većim brojem točno pronađenih stanica, iako i dalje je mnogo promašenih RBC-ova. Trombociti nisu uopće detektirani.


MCS3 je vjerojatno najgori do sad u ovom primjeru. WBC je točno detektiran, a RBC-ovi su detektirani relativno dobro, ali svejedno lošije od CST-YOLO i MCS2.

WELAN3 pokazuje vrlo slične rezultate kao i MCS2 s savršeno detektiranim WBC i dobro detektiranim RBC-ovima. Detektiran je gotovo isti broj RBC-ova iako različiti, no i dalje većina RBC-ova ostaju točni uz nekoliko lažno negativnih.

WELAN4 kao i ostali modeli odlično detektira WBC, ali broj detektiranih RBC-ova je malo manji od prošlih modela, no detekcija RBC-ova i dalje ostaje relativno dobra. Trombociti također nisu prepoznati.

U ovom primjeru iako je svim modelima odlična detekcija WBC-a, te dobra detekcija RBC-a, CST-YOLO je najnapredniji jer jedini detektira očekivani trombocit.

Usporedba 4



Slika 29 Usporedba 4

U ovoj usporedbi ponovno se analiziraju pet različitih modela na slici 30 (redom CST-YOLO slika 50, MCS2 slika 51, MCS3 slika 52, WELAN3 slika 53 i WELAN4 slika 54) detekcije krvnih stanica na istoj mikroskopskoj slici (00410 dataseta CBC [14]), s ciljem evaluacije njihove preciznosti u odnosu na stvarnu vrijednost (slika 55).

CST-YOLO postiže solidnu detekciju WBC-a, pravilno locirajući bijelu krvnu stanicu iako s malo manjim okvirom detekcije nego očekivanim. Crvene krvne stanice su također

detektirane u velikom broju, no s nešto nižom preciznošću, zbog više lažno negativnih slučajeva i nekoliko lažno pozitivnih rezultata. Trombociti nisu detektirani, iako su jasno označeni na slici „istina“.

MCS2 ispravno detektira WBC, sličnim okvirom kao CST-YOLO. Broj detektiranih RBC-ova je gotovo jednak, ali s ponegdje višim i ponegdje manjim vrijednostima sigurnosti. Također može se primijetiti jedan manje lažno pozitivan detektiran RBC.


MCS3 postiže gotovo identične rezultate kao i CST-YOLO, s odlično detektiranim WBC i dobrom detekcijom RBC-ova, ali kao i kod CST-YOLO, detekcija RBC-ova nije idealna. Trombociti opet nisu prepoznati.

WELAN3 model prvi pokazuje napredak u detekciji trombocita, što je odličan rezultat naprema drugim modelima iako su ostala tri trombocita i dalje ne detektirana. Detekcija WBC-a je odlična, a detekcija RBC-ova je relativno ista kao i kod prijašnjih modela s nekoliko točnih, nekoliko lažno pozitivnih i nekoliko lažno negativnih.

WELAN4 ostvaruje najbolju detekciju RBC-a, s samo jednim lažno negativnim, ali i dalje sadrži nekoliko lažno pozitivnih. Također, kao i prijašnji modeli, odlično detektira WBC. Trombociti nisu detektirani.

Modeli konzistentno točno prepoznaju WBC stanice. Detekcija RBC-a je dobra, iako s velikim prostorom za napredak. Trombociti su bili najveći izazov i u ovom primjeru, gdje je samo WELAN3 uspješno detektirao, iako samo jednog od četiri. U ovom primjeru kao najtočniji modeli ističu se WELAN3 i WELAN4. WELAN4 s najboljom preciznošću RBC-ova, a WELAN3 s najboljom preciznošću trombocita.

Usporedba 5



Slika 30 Usporedba 5

Ova slika prikazuje usporedbu rezultata detekcije modela (redom CST-YOLO slika A1, MCS2 slika A2, MCS3 slika A3, WELAN3 slika B1 i WELAN4 slika B2) na istom primjeru mikroskopske slike (00249 *dataset-a bccd* [13]). Donja desna slika B3 prikazuje stvarnu vrijednost. Međutim, već na prvi pogled, stvarna vrijednost djeluje nepouzđano ili čak pogrešno.

Na slici 61 prikazana su samo tri označena objekta: dva okvira detekcije za bijele krvne stanice (WBC) i jedan za trombocit. Međutim, ljudskim okom jasno je vidljiv veći broj crvenih krvnih stanica (RBC) koje nisu označene. Ovaj problem se ne pojavljuje samo na ovoj slici, već je prisutan i u brojnim drugim primjerima (slika 23, slika 29 su jedne od isto izraženih), no ovdje je posebno izražen. To upućuje na to da su anotacije vjerojatno nepotpune, što predstavlja ozbiljan problem. Modeli uče na temelju netočnih ili nedosljednih podataka, što izravno utječe na njihovu preciznost. Tijekom treniranja, modeli koji ispravno detektiraju stanice koje nisu označene u stvarnoj vrijednosti (eng. *ground truth*), zapravo uče da ih ignoriraju. S druge strane, ostaje otvorena mogućnost da anotacije možda nisu pogrešne, već da postoje medicinski opravdani razlozi zašto određene stanice nisu označene. Zbog toga bi sljedeći korak trebao biti

konzultacija s medicinskim stručnjakom kako bi se utvrdila ispravnost i potpunost dostupnih anotacija.

4. Zaključak

U ovom radu istražene su mogućnosti poboljšanja modela CST-YOLO za detekciju i lokalizaciju krvnih stanica u mikroskopskim slikama, s posebnim naglaskom na optimizaciju računalne složenosti i brzine bez značajnog gubitka točnosti. Kroz četiri modificirane verzije modela (MCS2, MCS3, WELAN3 i WELAN4) pokazali smo da je moguće postići značajno smanjenje računske složenosti (GFLOPS) i broja parametara, uz zadržavanje ili čak poboljšanje ključnih metrika kao što su preciznost, odziv i mAP.

Kvantitativnom analizom, predloženi model MCS2 istaknuo se kao najefikasniji od predloženih modela u smislu smanjenja računske složenosti (GFLOPS: 0.663) uz zadržavanje prihvatljive točnosti, što ga čini idealnim izborom za aplikacije gdje je brzina ključna. S druge strane, WELAN4 postigao je najbolje rezultate u pogledu točnosti (mAP@.5: 0.748), uz umjereno smanjenje broja parametara (0.891), što ga čini najboljim izborom za situacije gdje je preciznost prioritet. Model WELAN3 posebno se istaknuo u detekciji trombocita, što je bio izazov za sve modele, postižući najveću točnost (78%) u toj klasi.

Kvalitativnom analizom pokazali smo primjere kojima potvrđujemo efikasnost modela WELAN4 i WELAN3, te i uspješnost modela WELAN3 u detekciji trombocita, koja je bila najveći problem kroz analizu zbog podešenog visokog parametra praga pouzdanosti. Uz to pokazali smo prednosti i nedostatke modela s pomoću njihovih primjera. Međutim, kvalitativna analiza je također otkrila potencijalne nedostatke u anotacijama skupa podataka, posebno u označavanju crvenih krvnih stanica, što može negativno utjecati na performanse svih modela, što otežava evaluaciju gotovog modela. Ovo ukazuje na potrebu za provjerom i potencijalnom doradom anotacija u suradnji s medicinskim stručnjacima.

Zaključno, optimizirane verzije CST-YOLO modela pokazuju obećavajuće rezultate, ali budući rad trebao bi se usmjeriti na daljnje poboljšanje detekcije trombocita te validaciju na širem i pouzdanijem skupu podataka. Glavni modeli koji se ističu su WELAN3, WELAN4 i MCS2, te njihovo daljnje optimiziranje uz višestruku validaciju i bolju bazu podataka, mogu

potencijalno dovesti do odličnih rezultata u primjenama koje traže veću brzinu uz solidnu preciznost. Ipak u primjenama kao što je medicinska analiza slika, bitnija je točnost prije same brzine, pa ako je potrebno odabrati najbolji model za naš problem lokalizacije i klasifikacije krvnih stanica, ispravan bi odabir bio CST-YOLO ili WELAN4 zbog svojih najviših točnosti.

Literatura

- [1] T. G. S. G. O. M. J. ., P. I. Ibomoiye Domor Mienye, »Deep Convolutional Neural Networks in Medical Image Analysis: A Review,« *MDPI Information*, svez. 16, br. 3, 2025.
- [2] P.-Y. C. J.-W. L. Shin-Jye Lee, »Complete Blood Cell Detection and Counting Based on Deep Neural Networks,« *mdpi Applied Sciences*, svez. 12, br. Artificial Intelligence Developments in Healthcare: Diagnosis, Rehabilitation and Screening.
- [3] J.-T. T. W.-H. H. Yao-Mei Chen, »Automatic identifying and counting blood cells in smear images by using single shot detector and Taguchi method,« *BMC Bioinformatics*, svez. 22, br. 5, 2021.
- [4] T. H. C. D. P. N. A. A. P. Korranat Naruenatthanaset, »Red Blood Cell Segmentation with Overlapping Cell Separation and Classification on Imbalanced Dataset,« *arXiv:2012.01321*.
- [5] C.-M. T. F. F. T. R. P. Ming Kang, »CST-YOLO: A novel method for blood cell detection based on improved YOLOv7 and CNN-swin transformer,« u *2024 IEEE International Conference on Image Processing (ICIP)*, 2024.
- [6] mkang315, »<https://github.com/mkang315/CST-YOLO>,« [Mrežno]. Available: <https://github.com/mkang315/CST-YOLO>. [Pokušaj pristupa 18 6 2025].
- [7] LukaSpiljak-fer, »github.com/LukaSpiljak-fer/CST-YOLO,« [Mrežno]. Available: <https://github.com/LukaSpiljak-fer/CST-YOLO>. [Pokušaj pristupa 18 6 2025].

- [8] S. D. R. G. a. A. F. J. Redmon, »You Only Look Once: Unified, Real-Time Object Detection,« *arXiv:1506.02640*, 2016.
- [9] I.-H. Y. a. H.-Y. M. L. C.-Y. Wang, »YOLOv9: Learning What You Want to Learn Using Programmable Gradient Information,« *arXiv:2402.13616*.
- [10] A. B. a. H.-Y. M. L. C.-Y. Wang, »YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors,« *arXiv:2207.02696*, 2022.
- [11] T. L. R. Y. W. J. G. W. Chengjuan Gong, »A Hybrid Algorithm with Swin Transformer and Convolution for Cloud Detection,« *Remote Sensing*, svez. 15, br. 21, 2023.
- [12] Y. Z. J. L. D. L. C. C. Y. L. X. Z. P. L. T. M. Guoxu Liu, »An improved YOLOv7 model based on Swin Transformer and Trident Pyramid Networks for accurate tomato detection,« *Frontiers in Plant Science*, svez. 15, 2024.
- [13] S. Cheng, »Bccd (blood cell count and detection) dataset,« GitHub, 2019. [Mrežno]. Available: https://github.com/Shenggan/BCCD_Dataset. [Pokušaj pristupa June 2025].
- [14] M. M. Alam, »Complete blood count (cbc) dataset,« 2021. [Mrežno]. Available: <https://github.com/MahmudulAlam/Complete-Blood-Cell-Count-Dataset>. [Pokušaj pristupa June 2025].
- [15] A. Dongre, »Blood cell detection dataset,« 2021. [Mrežno]. Available: <https://www.kaggle.com/datasets/adhoppin/blood-cell-detection-datataset>. [Pokušaj pristupa June 2025].
- [16] M. M. A. a. M. T. Islam, »Machine learning approach of automatic identification and counting of blood cells,« *Healthc. Technol. Lett.*, svez. 6, br. 4, pp. 103-108, 2019.

Sažetak

Ovaj rad fokusira se na poboljšanje modela CST-YOLO, hibridne arhitekture koja kombinira YOLOv7 i CNN-SWIN Transformator, za detekciju i klasifikaciju crvenih krvnih stanica, bijelih krvnih stanica i trombocita u mikroskopskim slikama. Glavni cilj bio je optimizirati izvorni model kako bi se smanjila njegova računska složenost i povećala brzina uz očuvanje visoke točnosti.

U radu su predložene četiri modifikacije izvorne arhitekture: MCS2 i MCS3, modeli s pojednostavljenom verzijom modula Multiscale Channel Split (MCS) s manjim brojem grana, i WELAN3 i WELAN4, modeli s pojednostavljenom verzijom Weighted-ELAN modula sa smanjenim brojem konvolucijskih blokova.

Rezultati pokazuju da su svi optimizirani modeli postigli smanjenje računalne složenosti i povećanu brzinu uz zadržavanje konkurentne točnosti. Najefikasnijim modelom pokazao se MCS2 s 156.1 GFLOPS u usporedbi s izvornih 235.4 GFLOPS. WELAN4 postigao je najbolji mAP@0.5 (0.748), dok je WELAN3 pokazao najveću točnost u detekciji trombocita (78%).

Međutim, kvalitativna analiza otkrila je probleme s nedosljednim označavanjem podataka, što ukazuje na potrebu za boljim anotacijama. Također potrebna je višestruka validacija za točnije i sigurnije rezultate.

This thesis focuses on improving the CST-YOLO model, a hybrid architecture combining YOLOv7 and CNN-SWIN Transformer, for the detection and classification of red blood cells, white blood cells, and platelets in microscopic images. The main goal was to optimize the original model to reduce its computational complexity and increase speed while maintaining high accuracy.

Four modifications of the original architecture were proposed: MCS2 and MCS3, models with a simplified version of the Multiscale Channel Split (MCS) module with fewer branches, and WELAN3 and WELAN4, models with a simplified version of the Weighted-ELAN module with a reduced number of convolutional blocks.

The results show that all optimized models achieved a reduction in computational complexity and increased speed while maintaining competitive accuracy. The most effective model proved to be MCS2 with 156.1 GFLOPS compared to the original 235.4 GFLOPS. WELAN4 achieved the best mAP@0.5 (0.748), while WELAN3 showed the highest accuracy in platelet detection (78%).

However, qualitative analysis revealed issues with inconsistent data annotation, indicating the need for better annotations. Multiple validations are also needed for more accurate and reliable results.